API del Extractor DIAN

Rutas del API Laravel para extraer facturas de la DIAN desde sistemas externos. El API orquesta el worker Node (navegador) que obtiene los documentos del catálogo y luego consulta y procesa los XML con el certificado de la empresa.

Fuente: docs/API_EXTRACTOR.md · rama master · repositorio co-apidian2026 · commit afc068b0 · 14 de agosto de 2026

Las respuestas replican la estructura del extractor (`parseUblXml`): claves como `TipoDocumento` , `CUFE` , `Sub Total` , `TaxBreakdown` , `LineItems` , etc.

Autenticación: token de empresa

Todas las rutas se autentican con el token de la empresa (el mismo `api_token` que usa la empresa para los eventos RADIAN). No se envía ningún certificado en la petición: el API usa el certificado que la empresa ya tiene configurado para consultar los XML en la DIAN. La respuesta son los datos ya extraídos y procesados, no solo los CUFE.

- **Ventaja:** el cliente no expone su `.p12` en cada llamada; reutiliza la configuración de su empresa.
- **Requisito:** la empresa debe existir y tener software y certificado configurados (lo mismo que ya necesita para emitir o enviar documentos).

```
Authorization: Bearer <api_token de la empresa>
```

Base URL de ejemplo: `https://api.tu-dominio.com`

Resumen de rutas

Método	Ruta	Auth	Devuelve
POST	`/api/extractor/company/stream`	Bearer empresa	JSON `{ log, data }` al terminar. Un solo endpoint.
POST	`/api/extractor/company`	Bearer empresa	`jobId` (async, alternativa)
GET	`/api/extractor/company/jobs/{id}`	Bearer empresa	Avance y datos procesados
POST	`/api/ubl2.1/xml/document/{cufe}`	Bearer empresa	XML (base64) de un documento por CUFE

Dos formas de consumir el mismo flujo con token de empresa:

- **`/stream`** (simple, recomendado para clientes): un solo endpoint. Se llama una vez y devuelve el JSON `{ log, data }` cuando termina el proceso.
- **Async + polling** (`/company` + `/company/jobs/{id}`): para procesos largos o detrás de un proxy con timeout corto. Se llama y se interroga por `jobId` .

Campo tipo (Received | Sent)

Aplica a todos los flujos de extracción.

- **Received** (recibidos): documentos que le emitieron a la empresa. Se valida que la empresa sea el adquiriente. Solo estos se pueden registrar en eventos RADIAN.
- **Sent** (enviados): documentos que la empresa emitió. Son solo para el reporte (no aplican eventos RADIAN). No se valida el adquiriente, así que los documentos válidos vuelven con estado `ok`.

1. POST /api/extractor/company/stream

Una sola llamada que hace todo el proceso (obtiene los CUFE con el navegador y consulta cada XML con el certificado de la empresa) y devuelve el JSON `{ log, data }` cuando termina. La respuesta llega completa al final, no es en vivo, como el extractor original.

Autenticación

```
Authorization: Bearer <api_token de la empresa>
```

Petición

```
{
  "tipo": "Received",
  "fechaDesde": "2025-08-01",
  "fechaHasta": "2025-08-31",
  "url": "https://catalogo-vpfe.dian.gov.co/User/AuthToken?..."
}
```

Respuesta (application/json)

Al terminar el proceso devuelve un JSON con `log` (las líneas del proceso) y `data` (los documentos procesados):

```
{
  "log": [
    "Extracción iniciada",
    "Obteniendo CUFEs del catálogo DIAN…",
    "Página 1",
    "CUFEs obtenidos: 9. Consultando la DIAN por cada uno…",
    "Procesado 1/9 [ok]",
    "Procesado 9/9 [ok]",
    "Proceso terminado"
  ],
  "data": [
    { "TipoDocumento": "Invoice", "CUFE": "...", "Sub Total": 99495.8, "TaxBreakdown": [], "LineItems": [] }
  ]
}
```

Cómo consumirlo

```
const res = await fetch('https://api.tu-dominio.com/api/extractor/company/stream', {
  method: 'POST',
  headers: { 'Authorization': 'Bearer TOKEN_EMPRESA', 'Content-Type': 'application/json' },
  body: JSON.stringify({
    tipo: 'Received',
    fechaDesde: '2025-08-01',
    fechaHasta: '2025-08-31',
    url: '...'
  }),
});
const { log, data } = await res.json();
console.log(data);
```

```
curl -X POST https://api.tu-dominio.com/api/extractor/company/stream \
  -H "Authorization: Bearer TOKEN_EMPRESA" -H "Content-Type: application/json" \
  -d '{"tipo":"Received","fechaDesde":"2025-08-01","fechaHasta":"2025-08-31","url":"https://catalogo-
vpfe.dian.gov.co/User/AuthToken?..."}'
```

> El proceso puede tardar minutos. Si el API está detrás de un proxy con límite de tiempo (por ejemplo nginx a 60 s), para rangos grandes use el modo async + polling (sección 2), que no depende de mantener la conexión abierta.

2. POST /api/extractor/company

Arranca el proceso con el certificado de la empresa autenticada. Es asíncrono: devuelve un `jobId` al instante (el proceso tarda minutos) y el resultado se consulta con la ruta de estado.

Petición

```
{
  "tipo": "Received",
  "fechaDesde": "2025-08-01",
  "fechaHasta": "2025-08-31",
  "url": "https://catalogo-vpfe.dian.gov.co/User/AuthToken?pk=...&rk=...&token=...",
  "excluirEstados": null
}
```

Campo	Tipo	Obligatorio	Descripción
`tipo`	Sent | Received	Sí	Documentos enviados o recibidos.
`fechaDesde`	YYYY-MM-DD	Sí	Inicio del rango.
`fechaHasta`	YYYY-MM-DD	Sí	Fin del rango.
`url`	string (URL)	Sí	Enlace User/AuthToken de DIAN. Debe ser del mismo ambiente (Producción o Habilitación) que la empresa.
`excluirEstados`	string	No	Estados RADIAN a excluir.

Respuesta (202)

```
{
  "success": true,
  "jobId": "3f2a...-...-...",
  "statusUrl": "https://api.tu-dominio.com/api/extractor/company/jobs/3f2a...",
  "message": "Extracción iniciada. Consulte statusUrl para el avance y el resultado."
}
```

Error posible: **422** si la empresa está inactiva o no tiene software ni certificado.

3. GET /api/extractor/company/jobs/{id}

Se consulta por polling hasta `status: done` o `error`. En cada consulta el proceso avanza: primero obtiene los CUFE (navegador) y luego consulta y procesa los documentos con el certificado de la empresa por lotes. Conviene

consultar cada pocos segundos; ninguna consulta tarda mucho.

Mientras corre

```
{
  "success": true,
  "status": "running",
  "stage": "getting_cufes",
  "total": 0,
  "processed": 0,
  "log": [ "Extracción iniciada", "Obteniendo CUFEs del catálogo DIAN…" ]
}
```

`stage` refleja el flujo en vivo: `getting_cufes` → `enriching` → `done`.

```
{
  "success": true,
  "status": "running",
  "stage": "enriching",
  "total": 9,
  "processed": 5,
  "log": [ "CUFEs obtenidos: 9. Consultando la DIAN por cada uno…", "Procesados 5/9 documento(s)…" ]
}
```

Al terminar (status: done)


```
{
  "success": true,
  "status": "done",
  "stage": "done",
  "total": 9,
  "processed": 9,
  "log": [ "Procesados 9/9 documento(s)…", "Proceso terminado" ],
  "data": [
    {
      "TipoDocumento": "Invoice",
      "TipoBusqueda": "Received",
      "Numero de Factura": "FEBC24",
      "CUFE":
"41a77209dcc997ca657d4f858f09c93c41dcc7149ff25c525190f3a5d0d4af7b72d7e3179780096c7b9249a52d5c5136",
      "Fecha de Creación": "2025-08-05",
      "Fecha de Vencimiento": "2025-08-05",
      "Moneda": "COP",
      "NIT del Emisor": "901846280",
      "Razon Social del Emisor": "DIGITAL BÚHO SAS",
      "NIT del Receptor": "901827899",
      "Razon Social del Receptor": "CASA ESPIRITU S A S",
      "Metodo de Pago": "10",
      "Sub Total": 99495.8,
      "Impuestos Cabecera": 18904.2,
      "Retenciones": 0,
      "Total a Pagar": 118400,
      "TaxBreakdown": [
        { "code": "01", "name": "IVA", "percent": 19, "taxable_amount": 99495.8, "amount": 18904.2 }
      ],
      "LineItems": [
        {
          "Nombre del Producto": "Certificados Firma Digital - DIAN Colombia - Anual",
          "Referencia": "CFC-A",
          "Unidad de Medida": "94",
          "Cantidad": 1,
          "Precio Unitario": 143273.95,
          "Total": 99495.8,
          "taxes": [
            { "code": "01", "name": "IVA", "percent": 19, "taxable_amount": 99495.8, "amount": 18904.2 }
          ],
          "total_tax_line": 18904.2
        }
      ]
    }
  ]
}
```


Estados

status	Significado
`running`	En proceso. Ver `stage` y `log`.
`done`	Terminado. `data` trae los documentos procesados.
`error`	Falló. Ver `message` y `log`.
`404`	Job expirado, inexistente o de otra empresa.

Recomendación de polling: cada 3 a 5 segundos. Los jobs viven unas 2 horas en caché y luego se limpian.

4. POST /api/ubl2.1/xml/document/{cufe}

Endpoint existente del API. Consulta en la DIAN el XML de un documento por su CUFE (va en la URL) usando el certificado de la empresa autenticada. Devuelve la respuesta de la DIAN con el XML en base64 (`XmlBytesBase64`).

La pestaña **Consulta por CUFE** de la interfaz usa `POST /api/cufes/enrich` con `items: [{cufe}]` e `include_xml: true` . En una sola consulta devuelve los datos estructurados (`dian`) y el XML (`xml_b64`). Este endpoint sigue disponible si solo se necesita el XML crudo.

Petición

El CUFE va en la URL. En el body, `is_event: true` consulta por el endpoint de eventos (documentos recibidos).

```
POST /api/ubl2.1/xml/document/41a77209dcc997ca657d4f858...
{ "is_event": true }
```

Respuesta

```
{
  "success": true,
  "message": "Consulta generada con éxito",
  "ResponseDian": {
    "Envelope": { "Body": { "GetXmlByDocumentKeyResponse": { "GetXmlByDocumentKeyResult": {
      "Code": "100",
      "XmlBytesBase64": "PD94bWwgdmVyc2lvbj0iMS4w..."
    } } } }
  },
  "certificate_days_left": 123
}
```

El XML va en `ResponseDian → Envelope → Body → GetXmlByDocumentKeyResponse → GetXmlByDocumentKeyResult → XmlBytesBase64` . Hay que decodificar el base64 para obtener el XML UBL. Si el documento viene envuelto en un `AttachedDocument` , la factura real está embebida en un `cbc:Description` .

Ejemplo (cURL)

```
curl -X POST https://api.tu-dominio.com/api/ubl2.1/xml/document/41a77209... \
  -H "Authorization: Bearer TOKEN_EMPRESA" -H "Content-Type: application/json" \
  -d '{"is_event":true}'
```

Registrar en eventos RADIAN

Opcional, después de la consulta. Solo para documentos recibidos por esta empresa: el backend valida el adquiriente y rechaza si no aplica.

```
curl -X POST https://api.tu-dominio.com/api/load-document-by-cufe \
  -H "Authorization: Bearer TOKEN_EMPRESA" -H "Content-Type: application/json" \
  -d '{"cufe":"41a77209...","save":true}'
```

Códigos de error comunes

Código	Significado
401	Falta o es incorrecto el `Authorization: Bearer` de la empresa.
422	Validación fallida, empresa inactiva o sin software/certificado, o `EXTRACTOR_URL` no configurada.
404	Job expirado, inexistente o de otra empresa.
502	No se pudo conectar al worker, o error al consultar el extractor.
500	Error inesperado.

Notas de configuración

- `EXTRACTOR_URL` en el `.env` del API apunta al worker.
  - API en Docker: `http://cufes-worker:3001`
  - API en LAMP o servidor directo: `http://127.0.0.1:3001`
- **Ambiente del token:** el enlace `User/AuthToken` debe ser del mismo ambiente que la empresa y los documentos a consultar.
  - Producción: `catalogo-vpfe.dian.gov.co`
  - Habilitación: `catalogo-vpfe-hab.dian.gov.co`

Ejemplos rápidos (cURL)

Un solo endpoint: JSON { log, data } al terminar

```
curl -X POST https://api.tu-dominio.com/api/extractor/company/stream \
  -H "Authorization: Bearer EL_API_TOKEN_DE_LA_EMPRESA" \
  -H "Content-Type: application/json" \
  -d '{"tipo":"Received","fechaDesde":"2025-08-01","fechaHasta":"2025-08-31","url":"https://catalogo-
vpfe.dian.gov.co/User/AuthToken?..."}'
```

Async + polling

```
# 1) Iniciar la extracción. Devuelve jobId.
curl -X POST https://api.tu-dominio.com/api/extractor/company \
  -H "Authorization: Bearer EL_API_TOKEN_DE_LA_EMPRESA" \
  -H "Content-Type: application/json" \
  -d '{"tipo":"Received","fechaDesde":"2025-08-01","fechaHasta":"2025-08-31","url":"https://catalogo-
vpfe.dian.gov.co/User/AuthToken?..."}'

# 2) Consultar avance y resultado (polling cada 3-5 s hasta status "done")
curl https://api.tu-dominio.com/api/extractor/company/jobs/EL_JOB_ID \
  -H "Authorization: Bearer EL_API_TOKEN_DE_LA_EMPRESA"
```

Documento generado a partir de la vista previa de GitLab: https://git.buho.la/facturalatam/apidian/co-apidian2026/-/blob/master/docs/API_EXTRACTOR.md